

Pomiar ryzyka rynkowego cz. 3

23.05.2023

1 Metody testowania wstecznego (*backtesting*) dla wartości zagrożonej

Przypomnijmy przykład dotyczący testowania wstecznego.

Rozważmy miarę ryzyka określoną jako kwantyl ($\alpha\%$) rozkładu zmiennej ryzyka (**ta miara to właśnie wartość zagrożona, VaR**). Jeśli wartość tego kwantyla została oszacowana poprawnie, to dla danych z niedalekiej przyszłości ilość stóp zwrotu mniejszych niż ten kwantyl powinna wynosić około $\alpha\%$.

Założmy, że mamy dane $(r_1, r_2, \dots, r_{2n})$ z okresu $(1, 2, \dots, 2n)$. Można zastosować następującą procedurę:

1. Szacujemy kwantyl rzędu α , K_α^1 na podstawie danych $(1, 2, \dots, n)$.
2. Sprawdzamy, czy wartość r_{n+1} przekracza K_α^1 . Podstawiamy $I_\alpha^1 = 1$, jeśli $r_{n+1} < K_\alpha^1$ lub $I_\alpha^1 = 0$, jeśli $r_{n+1} > K_\alpha^1$.
3. Szacujemy kwantyl rzędu α , K_α^2 na podstawie danych $(2, 3, \dots, n+1)$.
4. Sprawdzamy, czy wartość r_{n+2} przekracza K_α^2 . Podstawiamy $I_\alpha^2 = 1$, jeśli $r_{n+2} < K_\alpha^2$ lub $I_\alpha^2 = 0$, jeśli $r_{n+2} > K_\alpha^2$.
5. ...
6. Szacujemy kwantyl rzędu α , K_α^n na podstawie danych $(n, n+1, \dots, 2n-1)$.
7. Sprawdzamy, czy wartość r_{2n} przekracza K_α^n . Podstawiamy $I_\alpha^n = 1$, jeśli $r_{2n} < K_\alpha^n$ lub $I_\alpha^n = 0$, jeśli $r_{2n} > K_\alpha^n$.

Jeśli oszacowania są poprawne, to $(I_\alpha^1, I_\alpha^2, \dots, I_\alpha^n)$ powinno mieć rozkład Bernoulliego o średniej $E(I_\alpha) = \alpha$ i wariancji $Var(I_\alpha) = \alpha(1 - \alpha)$.

W dalszej części wprowadzimy testy bazujące na własnościach wektora przekroczeń $(I_\alpha^1, I_\alpha^2, \dots, I_\alpha^n)$.
Uwaga: Długości okresu, z którego wyznaczamy VaR i okresu, dla którego wyznaczamy wektor przekroczeń mogą być różne.

1.1 Test pokrycia (test Kupca, *unconditional coverage test*)

Niech:

π - procent przekroczeń wynikający z danych (czyli średnia z wektora przekroczeń);

p - procent przekroczeń wynikający z założonego modelu (czyli α).

Możemy testować równość tych dwóch wartości. Test Kupca opiera się na następujących hipotezach:

$$H_0 : \pi = p,$$

$$H_1 : \pi \neq p.$$

Możemy zapisać funkcję wiarygodności z rozkładu Bernoulliego:

$$L(\pi) = \prod_{i=1}^n (1 - \pi)^{(1-I_i)} \pi^{I_i} = (1 - \pi)^{I_0} \pi^{I_1}, \quad (1)$$

gdzie I_0 - ilość zer, a I_1 - ilość jedynek w wektorze przekroczeń.

Zatem dla estymatora średniej ilości przekroczeń $\hat{\pi} = \frac{I_1}{n}$ mamy:

$$L(\hat{\pi}) = \left(1 - \frac{I_1}{n}\right)^{I_0} \left(\frac{I_1}{n}\right)^{I_1}. \quad (2)$$

Jeżeli spełniona jest hipoteza H_0 , tzn. $\pi = p$, to również:

$$L(p) = (1 - p)^{I_0} (p)^{I_1}. \quad (3)$$

Możemy zastosować test ilorazu wiarygodności. Służy do porównywania dwóch modeli, z których jeden jest zagnieżdżony w drugim (tzn. ma w stosunku do niego ograniczoną przestrzeń parametrów). Formalnie: rozważmy model statystyczny z przestrzenią parametrów Θ . Niech Θ_0 będzie podprzestrzenią Θ , $\Theta_0 \subset \Theta$. Hipoteza H_0 mówi, że parametr modelu θ należy do przestrzeni Θ_0 , $H_0 : \theta \in \Theta_0$, tzn model z parametrami ograniczonymi do podprzestrzeni Θ_0 nie jest gorszy od modelu ogólniejszego. Hipoteza alternatywna przyjmuje postać $H_1 : \theta \in \Theta \setminus \Theta_0$. Wtedy statystyka testowa (nazywana ilorazem wiarygodności) przyjmuje postać:

$$LR = -2 \ln \left[\frac{\sup_{\theta \in \Theta_0} L(\theta)}{\sup_{\theta \in \Theta} L(\theta)} \right], \quad (4)$$

gdzie L to funkcja wiarygodności. Jeśli hipoteza H_0 jest spełniona, to statystyka LR zbiega asymptotycznie do rozkładu χ^2 z liczbą stopni swobody równą różnicy wymiarów pomiędzy Θ i Θ_0 .

W przypadku testu pokrycia modelem zagnieżdżonym jest model z ustaloną wartością p . Modelem ogólniejszym jest model, w którym dopuszczamy różne wartości procentu przekroczeń. W tym przypadku funkcja wiarygodności osiąga supremum dla parametru $\hat{\pi}$. Zatem iloraz wiarygodności przyjmuje następującą postać:

$$LR = -2 \ln \left[\frac{L(p)}{L(\hat{\pi})} \right] = -2 \ln \left[\frac{(1 - p)^{I_0} (p)^{I_1}}{\left(1 - \frac{I_1}{n}\right)^{I_0} \left(\frac{I_1}{n}\right)^{I_1}} \right]. \quad (5)$$

Jeśli hipoteza H_0 jest prawdziwa, to $LR \sim \chi_1^2$. Zatem zarówno obszar krytyczny testu, jak i jego p -wartość można wyznaczyć bazując na dystrybucji rozkładu χ_1^2 . Na przykład przypomnijmy, że p -wartość to prawdopodobieństwo otrzymania większej wartości statystyki testowej przy prawdziwej hipotezie H_0 , czyli $P(X > LR) = 1 - \chi_1^2(LR)$, gdzie X to zmienna o rozkładzie χ_1^2 (statystyka testowa), LR to wartość statystyki otrzymana z danych, a $\chi_1^2(\cdot)$ to dystrybucja rozkładu χ_1^2 .

2 Literatura uzupełniająca

- [1] Alexander J. McNeil , Rudiger Frey, Paul Embrechts, Quantitative Risk Management, Princeton University Press, New Jersey, 2005,
- [2] Carol Alexander, Market Risk Analysis, vol. IV: Value at Risk Models, Wiley, Chichester, 2008,
- [3] Kevin Dowd, Measuring Market Risk, Wiley, 2002,
- [4] Philippe Jorion, Value at Risk, The New Benchmark for Managing Financial Risk, MCGraw-Hill, 2001.